

Enerji Tüketimi Odaklı Benchmark Değerlendirme Raporu

LLM Yapılandırılmış Çıktı Formatları Karşılaştırması

Bu rapor 7 model, 4 çıktı formatı ve 81 özet benchmark kaydı üzerinden hazırlanmıştır. Değerlendirme kalite skoru farkı yaratmadan, enerji tüketimi, güç kullanımı, token sayısı ve yanıt uzunluğu üzerinden yapılmıştır.

1. Temel Bulgular

- Format seçimi enerji tüketimini belirgin şekilde etkilemektedir.
- TONL ve XML genel ortalama en düşük enerji profiline sahiptir.
- YAML, özellikle highly-nested-multimodal görevlerde enerji maliyetini ciddi biçimde artırmaktadır.
- qwen2.5-14b model bazında en düşük ortalama enerji tüketimini göstermektedir.
- Token sayısı ve yanıt uzunluğu arttıkça enerji tüketimi de belirgin biçimde artmaktadır.

2. Formatların Enerji Tüketimi

Format	Kayıt	Ort. Enerji	Medyan	Toplam	Ort. Token	Ort. Karakter
TONL	18	1.8061	0.8928	32.5107	511.7	586.3
XML	21	2.0360	0.9141	42.7567	472.5	779.1
TOML	21	3.4152	1.0498	71.7198	541.8	623.1
YAML	21	8.2454	0.9595	173.1531	2343.0	5512.3

TONL ve XML daha düşük enerji tüketimiyle öne çıkarken, YAML en yüksek ortalama ve toplam enerji değerlerine sahiptir. YAML'in medyan değerinin düşük, ortalama değerinin ise yüksek olması belirli koşullarda enerji tüketiminin asiri yükseldiğini göstermektedir.

3. Gorev Karmasikligina Gore Format Etkisi

Gorev	Format	Ort. Enerji	Ort. Token	Ort. Karakter
simple	TOML	1.2942	296.6	192.1
simple	XML	1.4762	278.7	245.0
simple	TONL	1.4949	336.7	263.0
simple	YAML	2.0596	221.7	113.1
nested	TONL	1.2861	315.2	113.7
nested	XML	1.4219	211.3	140.1
nested	TOML	1.8312	294.0	151.1
nested	YAML	2.5445	215.1	92.6
highly-nested	TONL	2.6375	883.2	1382.2
highly-nested	XML	3.2099	927.4	1952.3
highly-nested	TOML	7.1202	1034.9	1526.0
highly-nested	YAML	20.1320	6592.0	16331.1

Simple ve nested gorevlerde format farki sinirliyen, highly-nested-multimodal gorevlerde YAML diger formatlardan belirgin sekilde ayrilmaktadir. Bu bulgu, karmasik gorevlerde format seciminin enerji maliyeti icin kritik hale geldigini gostermektedir.

4. Model Bazinda Enerji Tuketimi

Model	Kayit	Ort. Enerji	Medyan	Toplam	Ort. Token	Ort. Karakter
qwen2.5-14b	12	0.6966	0.4088	8.3590	164.5	533.7
gemma3-4b	12	0.8537	0.5510	10.2445	281.0	745.7
qwen3-0.6b-8bit	12	1.1177	0.9952	13.4128	582.8	494.8
mistral7b	12	2.3296	1.2367	27.9558	240.7	609.3
gpt-oss-20b-MXFP4-Q8	12	6.0452	3.5851	72.5428	1866.3	669.8
llama3.2-1b	12	7.4549	0.3810	89.4593	2852.3	9451.7
deepseekr1-qwen14	9	10.9073	10.2682	98.1660	873.6	633.2

qwen2.5-14b, gemma3-4b ve qwen3-0.6b-8bit dusuk enerji profiliyle one cikmaktadir. Deepseekr1-qwen14 en yuksek ortalama enerji tuketimine sahiptir. Llama3.2-1b modelinde ise cok uzun yanitlar, ortalama enerji maliyetini yukselten ana etkenlerden biridir.

5. Model-Format Kombinasyonlari

Model	En Dusuk Format	En Dusuk Format Enerji	En Yuksek Format	En Yuksek Format Enerji
deepseekr1-qwen14	XML	6.6699	TOML	13.6029
gemma3-4b	XML	0.4679	TOML	1.2606
gpt-oss-20b-MXFP4-Q8	XML	2.9600	YAML	11.5717
llama3.2-1b	TONL	0.2290	YAML	28.7000
mistral7b	XML	1.9293	TOML	2.6574
qwen2.5-14b	TONL	0.4588	XML	0.9344
qwen3-0.6b-8bit	TONL	0.9240	YAML	1.4534

Format etkisi modelden modele degismektedir. En carpici fark llama3.2-1b modelindedir: TONL formatinda 0.2290 mWh olan ortalama enerji, YAML formatinda 28.7000 mWh seviyesine cikmaktadir. Bu nedenle enerji odakli benchmarklarda

model-format kombinasyonlari ayri ayri incelenmelidir.

6. Sonuc ve Oneriler

- Genel enerji verimliliği için qwen2.5-14b ilk tercih olarak değerlendirilebilir.
- Düşük enerji isteyen uygulamalar için gemma3-4b ve qwen3-0.6b-8bit uygun alternatiflerdir.
- Format seçiminde TONL ve XML enerji açısından daha avantajlı görünmektedir.
- Karmaşık görevlerde YAML kullanımı enerji maliyeti nedeniyle dikkatle değerlendirilmelidir.
- Enerji bütçesi sınırlı sistemlerde uzun yanıt üreten model-format kombinasyonlari kontrollu kullanılmalıdır.